Лабораторная работа 1: Предварительный статистический анализ данных Фишера.

Общее задание:

Для данных Фишера (файл irisdat):

1. Проверить предположение о том, что математической моделью данных является модель «случайная выборка».
2. Исследовать закон распределения случайных выборок, соответствующих переменным var1–var4.
3. Проверить предположение о нормальном распределении выборок.
4. Исследовать однородность данных по среднему значению и дисперсии значений переменных var1–var4, относящихся к различным типам ирисов, видам 1, 2, 3 (var5).
5. С помощью графического анализа и тестовых статистик проверить предположение о присутствии в данных аномальных наблюдений.
6. Проверить гипотезу о том, что соответствующие выборки наблюдений являются случайными выборками из многомерного нормального распределения; дать содержательную интерпретацию этому предположению.

Указания:

- Исследование проводить по индивидуальным наборам данных для указанных переменных и выборок.
- Описание данных см. в прилагаемом файле.

Король Денис, 3 курс, 8а группа Вариант: type 3, "sepalwid"

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import scipy.stats as sts
```

In [2]:
```
from scipy.stats import ttest_ind
```

In [3]:
```
data = pd.read_excel('irisdat.xlsx')
print(data.shape)
data.head(3)
```

```
(150, 5)
```

Out[3]:

	sepallen	sepalwid	petallen	petalwid	type
0	5.0	3.3	1.4	0.2	1
1	6.4	2.8	5.6	2.2	3
2	6.5	2.8	4.6	1.5	2

In [4]:
```
data['type'].unique()
```

Out[4]:
```
array([1, 3, 2])
```

In [5]:
```
data.isna()
```

Out[5]:

	sepallen	sepalwid	petallen	petalwid	type
0	False	False	False	False	False
1	False	False	False	False	False
2	False	False	False	False	False
3	False	False	False	False	False
4	False	False	False	False	False
...	...	...	...	...	...
145	False	False	False	False	False
146	False	False	False	False	False
147	False	False	False	False	False
148	False	False	False	False	False
149	False	False	False	False	False

150 rows × 5 columns

In [6]:
```
data.isna().sum(axis=0)
```

Out[6]:
```
sepallen    0
sepalwid    0
petallen    0
petalwid    0
type        0
dtype: int64
```

Пропусков нет — данные полные, дополнительная обработка не требуется.

In [7]:
```
#вариант 6: sepalwid, type = 3
```

In [8]:
```
x = data[data['type'] == 3]['sepalwid'].values
print(x.shape)
x[:10]
```

```
(50,)
```

Out[8]:
```
array([2.8, 3.1, 2.8, 3.1, 3. , 3. , 2.7, 3.2, 3.4, 3.8])
```

Для случайной выборки необходимо чтобы данные были независимы и были из одного распределения. Исходя из условия задания подразумеваем, что данные удволетворяют модели "случайная выборка".

In [9]:
```
mean_val = x.mean().item()
var_val = x.var().item()
std_val = x.std().item()
```

In [10]:
```
print(f"Среднее: {mean_val:.4f}")
print(f"Дисперсия: {var_val:.4f}")
print(f"СКО: {std_val:.4f}")
```

```
Среднее: 2.9740
Дисперсия: 0.1019
СКО: 0.3193
```

Коэффицент ассиметрии и эксцесса

In [11]:
```
dev = x - mean_val

m2 = np.mean(dev ** 2)
m3 = np.mean(dev ** 3)
m4 = np.mean(dev ** 4)

asym = m3 / (m2 ** 1.5)
kurt =(m4/(m2 ** 2)) - 3
print(f"Коэффициент асимметрии: {asym :.4f}")
print(f"Коэффициент эксцесса (избыточный): {kurt :.4f}")
```

```
Коэффициент асимметрии: 0.3549
Коэффициент эксцесса (избыточный): 0.5198
```

Коэффициент асимметрии показывает скошенность распределения: он > 0 — правый хвост длиннее.

Коэффициент эксцесса (избыточный) показывает островершинность.

Полученные значения близки к нулю, что согласуется с гипотезой о нормальном распределении.

Правило трёх сигм

In [12]:
```
le = mean_val - 3*std_val
ri = mean_val + 3*std_val
print(f'({le:.3f}; {ri:.3f})')
```

```
(2.016; 3.932)
```

In [13]:
```
x[(x < le) | (x > ri)]
```

Out[13]:
```
array([], dtype=float64)
```

Для нормального распределения 99.73% значений лежат в интервале (μ − 3σ; μ + 3σ). Значения за границами — потенциальные выбросы.

Все наблюдения укладываются в интервал — грубых ошибок нет.

Устойчивые характеристики

Среднее и медиана. Среднее чувствительно к выбросам, медиана — устойчива.

In [14]:
```
x.min(), x.max()
```

Out[14]:
```
(np.float64(2.2), np.float64(3.8))
```

In [15]:
```
x.mean().item(), np.quantile(x, 0.5).item()
```

Out[15]:
```
(2.974, 3.0)
```

In [16]:
```
#среднее арифм - неустойчивое, медиана - устойчивая(центральный элемент отсортированной выборк
```

Сравнение эмпирических и теоретических квантилей

Если выборка нормальна, эмпирические квантили должны быть близки к квантилям теоретического нормального распределения.

Эмпирические:

In [17]:
```
np.quantile(x, 0.05).item(), np.quantile(x, 0.95).item()
```

Out[17]: (2.5, 3.5099999999999993)

Теоритические:

In [18]:
```
m = x.mean()
sigma = x.std(ddof=1)

sts.norm.ppf(0.05, m, sigma).item(), sts.norm.ppf(0.95, m, sigma).item()
```

Out[18]: (2.4435402350220805, 3.5044597649779194)

Также сравним межквартальный размах

In [19]:
```
np.quantile(x, 0.75).item() - np.quantile(x, 0.25).item()
```

Out[19]: 0.37500000000000044

In [20]:
```
sts.norm.ppf(0.75, m, sigma).item() - sts.norm.ppf(0.25, m, sigma).item()
```

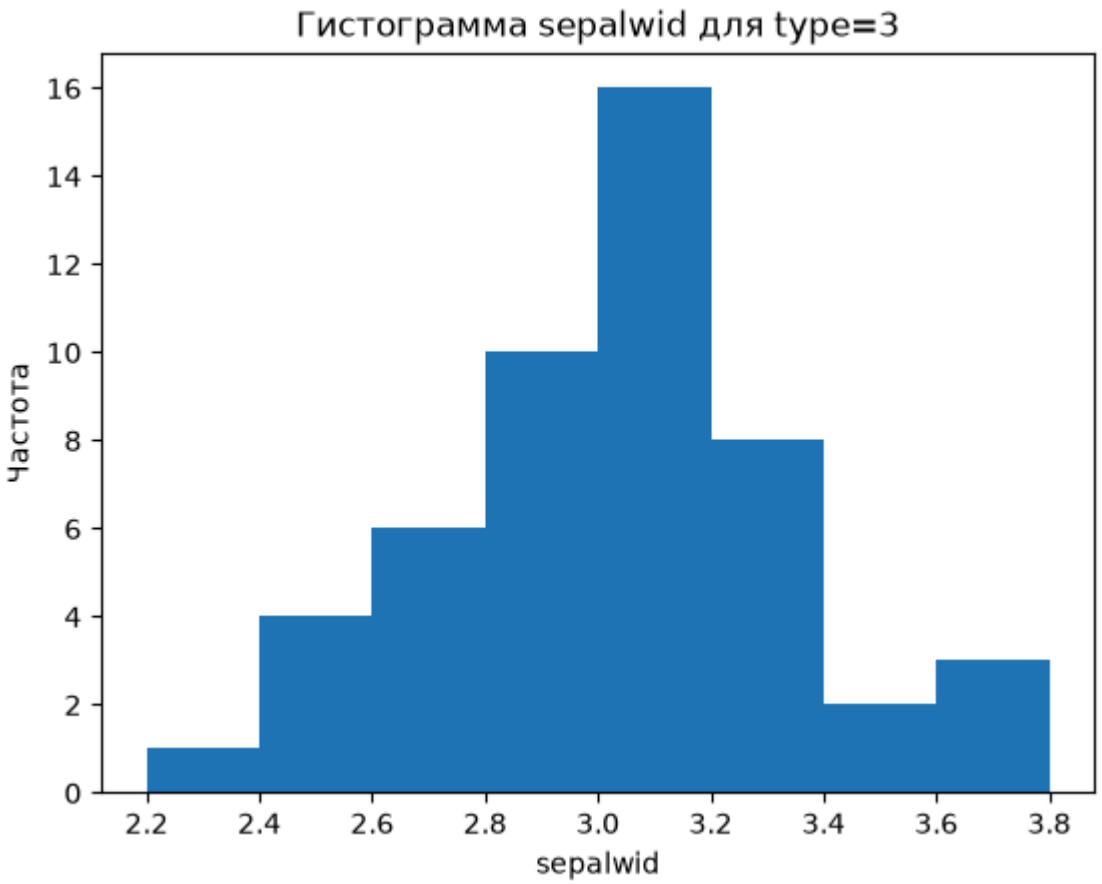
Out[20]: 0.4350413538402771

In [21]:
```
#аналог дисперсии, устойчивый к граничным(сильно отличающимся) значениям
```

Межквартильный размах практически совпадает. Это дополнительно подтверждает гипотезу о нормальности распределения.

Гистограмма

In [22]:
```
plt.hist(x, bins=8)
plt.title('Гистограмма sepalwid для type=3')
plt.xlabel('sepalwid')
plt.ylabel('Частота')
plt.show()
```



Гистограмма имеет выраженную одновершинную форму, близкую к симметричной. Она визуально согласуется с плотностью нормального распределения.

In [23]:
```
#аксцесс - то насколько острая гистограмма
#симметрия - то насколько тяжелые хвосты с одной из сторон гистограммы
```

In [24]:
```
#оценка плотности
```

Эмпирическая функция распределения

In [25]:
```
z = sorted(x)
t = np.linspace(0, 1, len(z))
plt.plot(z, t)
plt.title('Эмпирическая функция распределения')
plt.xlabel('sepalwid')
plt.ylabel('F(x)')
plt.show()
```

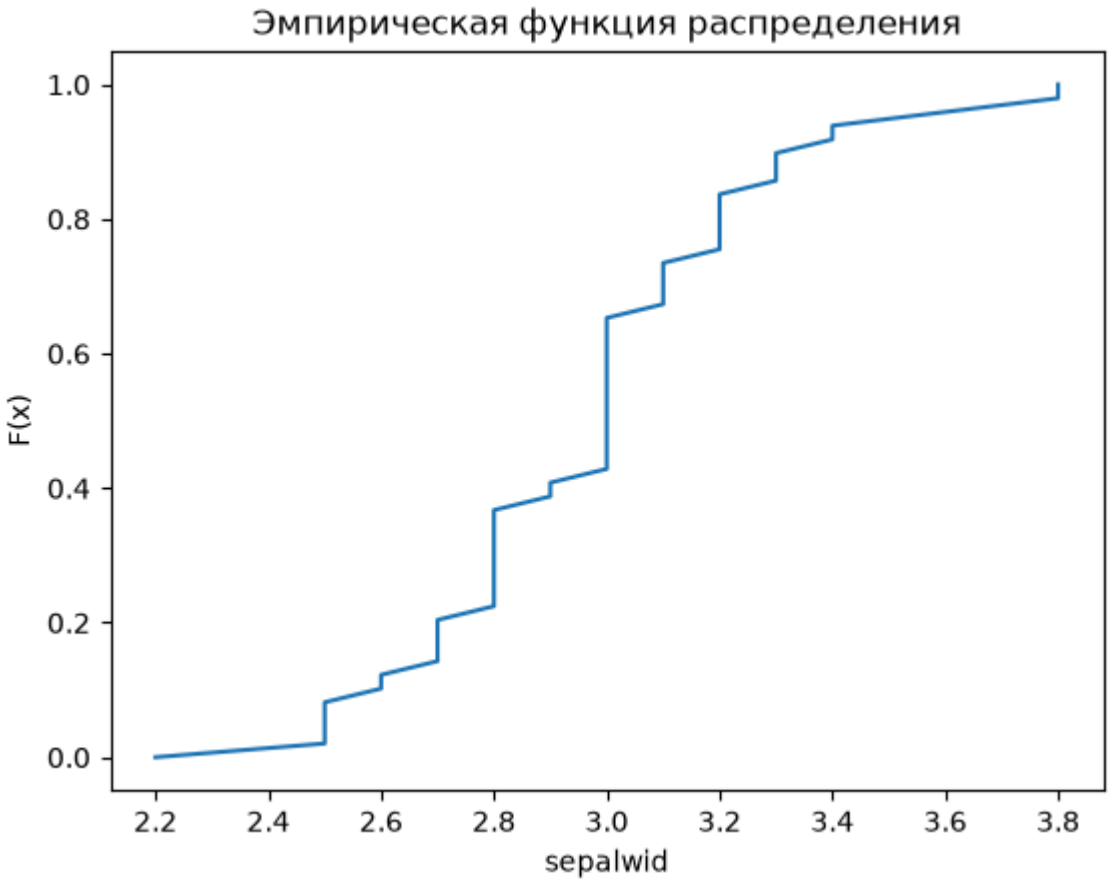
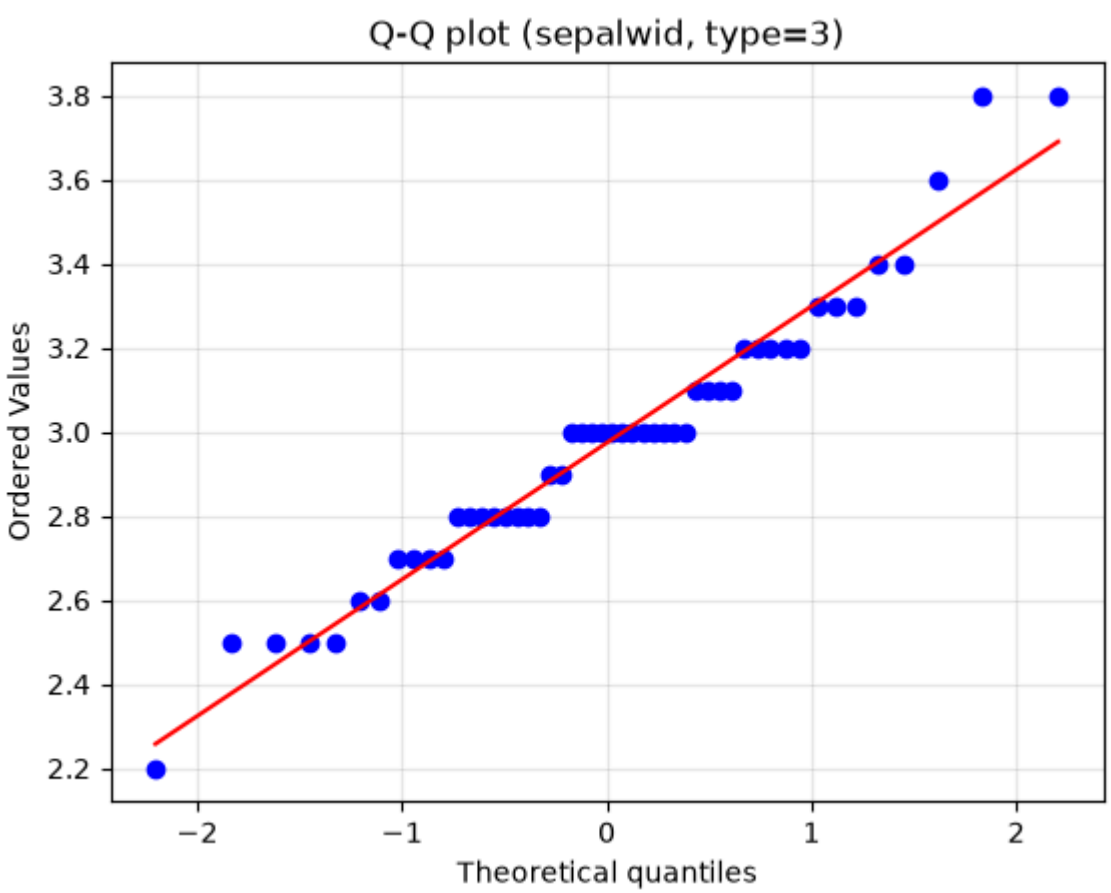


График визуально подтверждает гипотезу о нормальном распределении выборки.

График квантиль-квантиль

Сравнивает эмпирические квантили выборки с теоретическими квантилями нормального распределения.

In [26]:
```
sts.probplot(x, dist="norm", plot=plt)
plt.title("Q-Q plot (sepalwid, type=3)")
plt.grid(alpha=0.3)
plt.show()
```

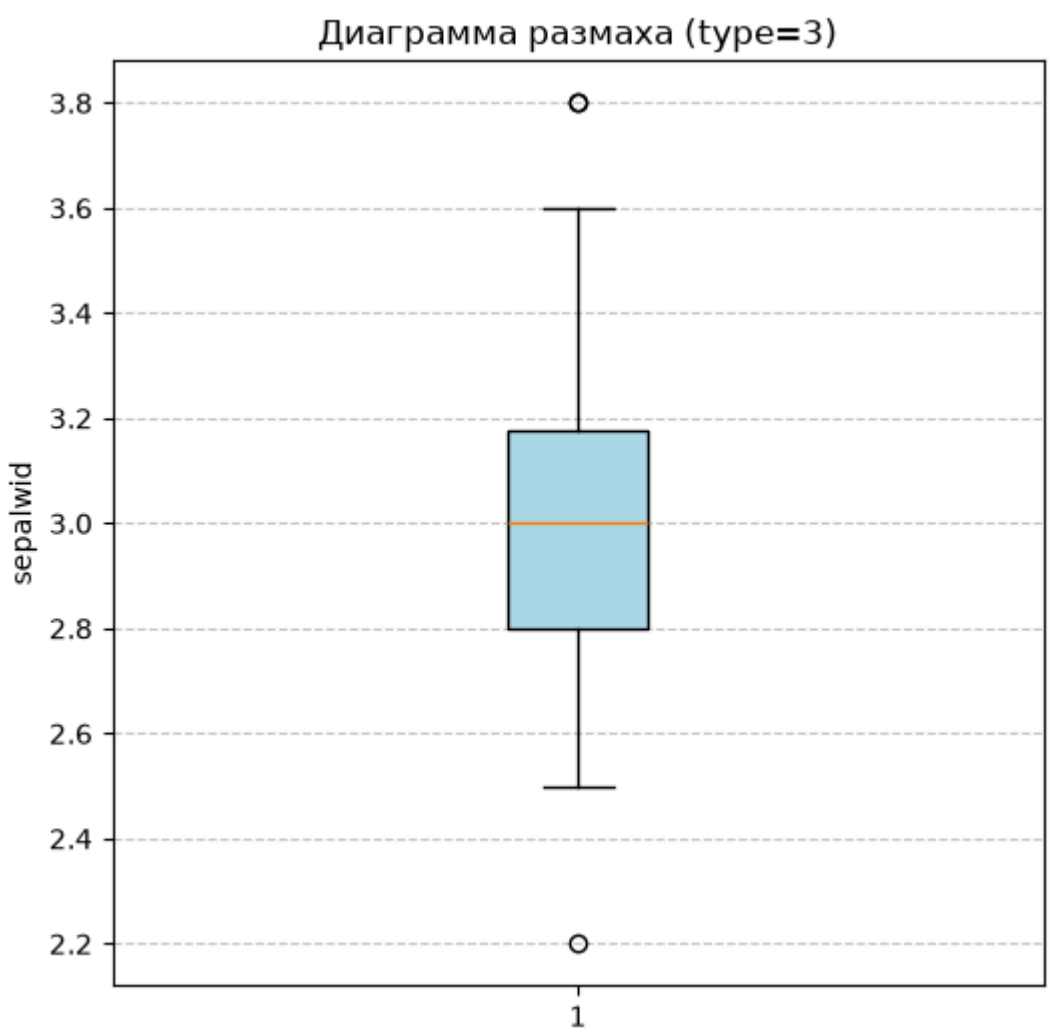


Данные нормальны — точки лежат на прямой линии. Небольшие отклонения на хвостах не критичны.

Диаграмма размаха (boxplot)

Показывает медиану, квартили, усы (границы 1.5·IQR) и выбросы (точки за усами).

In [27]:
```
plt.figure(figsize=(6, 6))
plt.boxplot(x, notch=False, patch_artist=True,
            boxprops=dict(facecolor="lightblue"))
plt.ylabel("sepalwid")
plt.title("Диаграмма размаха (type=3)")
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```



Медиана делит ящик почти пополам, длина верхнего и нижнего усов примерно одинакова — распределение симметричное. Есть два выброса, это не критично

Критерий Стьюдента

In [28]:
```
x1 = data[data['type'] == 1]['sepalwid'].values
x2 = data[data['type'] == 2]['sepalwid'].values
x3 = data[data['type'] == 3]['sepalwid'].values
t_stat, p_val = ttest_ind(x3, x1)
print(f"t-test 3 vs 1: t={t_stat:.4f}, p={p_val:.6f}")
t_stat, p_val = ttest_ind(x3, x2)
print(f"t-test 3 vs 2: t={t_stat:.4f}, p={p_val:.6f}")
```

```
t-test 3 vs 1: t=-6.4503, p=0.000000
t-test 3 vs 2: t=3.2058, p=0.001819
```

p < 0.05 - основание отвергнуть гипотезу о равенстве средних

In [29]:
```
F = x3.var(ddof=1) / x2.var(ddof=1)
df1, df2 = len(x3) - 1, len(x2) - 1
p = 2 * min(sts.f.cdf(F, df1, df2), 1 - sts.f.cdf(F, df1, df2))
print(f"F-test 3 vs 2: p={p:.6f}")
```

```
F-test 3 vs 2: p=0.848988
```

Если p >= 0.05 — нет оснований отвергнуть равенство дисперсий

Критерий согласия Пирсона

In [30]:
```
freq, edges = np.histogram(x, bins=5)
print("Частоты:", freq)
```

```
print("Границы:", edges)
```

```
Частоты: [ 5 14 18 10  3]
Границы: [2.2  2.52 2.84 3.16 3.48 3.8 ]
```

In [31]:
```
edges_inf = edges.copy()
edges_inf[0] = -np.inf
edges_inf[-1] = np.inf
```

In [32]:
```
mu_hat = x.mean()
sigma_hat = x.std(ddof=1)
```

In [33]:
```
p = sts.norm.cdf(edges_inf[1:], mu_hat, sigma_hat) - \
    sts.norm.cdf(edges_inf[:-1], mu_hat, sigma_hat)
np_ = p * len(x)
print("Ожидаемые частоты:", np_)
```

```
Ожидаемые частоты: [ 3.98000474 12.96424296 18.95304688 11.18655706  2.91614836]
```

In [34]:
```
chi2_stat, chi2_p = sts.chisquare(freq, np_, ddof=2)
print(f"Chi-square: stat={chi2_stat:.4f}, p={chi2_p:.4f}")
```

```
Chi-square: stat=0.5203, p=0.7709
```

p > 0.05 нет оснований отвергнуть гипотезу что согласуется с нормальным.

Вывод

Первичный статистический анализ ширины чашелистика ирисов типа 3 не даёт оснований для отклонения нулевой гипотезы H0 о нормальном законе распределения, так как аргументы в пользу этой модели преобладают. Коэффициент асимметрии (0.35) и эксцесс (0.52) близки к нулю, эмпирические квантили практически совпадают с теоретическими, а графики гистограммы, эмпирической функции распределения и Q-Q plot визуально подтверждают нормальность. В выборке наблюдается высокая симметрия и полное отсутствие аномальных выбросов по правилу трёх сигм, что дополнительно согласуется с гипотезой о нормальном распределении. Критерий согласия Пирсона ($p = 0.77 > 0.05$) также не отвергает H0.

При проверке однородности выявлено, что выборки sepalwid для типов 2 и 3 неоднородны по среднему значению (t-тест Стьюдента, $p < 0.05$): средняя ширина чашелистика у ирисов типа 3 значимо отличается от таковой у типа 2. Однако по дисперсии выборки можно считать однородными (F-тест Фишера, $p = 0.85 > 0.05$) — разброс значений внутри каждого типа примерно одинаков.