Лабораторная работа 2: Исследование зависимости между случайными величинами с помощью ВЧКК и ВМКК.

1. По результатам выполнения задания 3.2.1 найти значения ВЧКК `r_{1,2|3}` и `r_{1,3|2}`. Сравнить полученные значения с соответствующими оценками `r_{1,2}` и `r_{1,3}` для парных коэффициентов корреляции.
   - Что можно сказать о статистической значимости ВЧКК и ВКК?
   - Что является причиной корреляции между анализируемыми случайными величинами: непосредственная связь между ними или влияние третьего фактора?
2. По результатам выполнения задания 3.2.2 найти значение ВМКК `r_{1,2,3}`. Сравнить полученное значение:
   - а) с величиной `R` (где `R^2` — коэффициент детерминации для модели множественной линейной регрессии `x_1` на `x_{(2)}`);
   - б) с оценкой МКК, вычисляемой в разделе “Корреляционный анализ” компьютерного учебника.
   - Что можно сказать о статистической значимости полученного значения ВМКК?
3. Провести аналогичные исследования с альтернативными ППП. Сравнить полученные результаты.

Указания:

- Исследование проводить по индивидуальным наборам данных для указанных переменных и выборок.
- Описание данных см. в прилагаемом файле.

Король Денис, 3 курс, 8а группа

Вариант 6: type 3

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import scipy.stats as sts
from IPython.display import Image, display
```

Чтение данных из файла и формирование выборки

In [2]:
```
data = pd.read_excel('irisdat.xlsx')
print(data.shape)
data.head(3)
```

```
(150, 5)
```

Out[2]:

	sepallen	sepalwid	petallen	petalwid	type
0	5.0	3.3	1.4	0.2	1
1	6.4	2.8	5.6	2.2	3
2	6.5	2.8	4.6	1.5	2

Проверка пропусков

In [3]:
```
data.isna()
```

Out[3]:

	sepallen	sepalwid	petallen	petalwid	type
0	False	False	False	False	False
1	False	False	False	False	False
2	False	False	False	False	False
3	False	False	False	False	False
4	False	False	False	False	False
...	...	...	...	...	...
145	False	False	False	False	False
146	False	False	False	False	False
147	False	False	False	False	False
148	False	False	False	False	False
149	False	False	False	False	False

150 rows × 5 columns

In [4]:
```
data.isna().sum(axis=0)
```

Out[4]:
```
sepallen    0
sepalwid    0
petallen    0
petalwid    0
type        0
dtype: int64
```

Формирование выборки данных для варианта 6: type = 3, sepalwid, sepallen, petalwid

In [5]:
```
x1 = data[data['type'] == 3]['sepalwid'].values
x2 = data[data['type'] == 3]['sepallen'].values
x3 = data[data['type'] == 3]['petalwid'].values
print(x1.shape)
print(x2.shape)
print(x3.shape)
x1[:6], x2[:6], x3[:6]
```

```
(50,)
(50,)
(50,)
```

Out[5]:
```
(array([2.8, 3.1, 2.8, 3.1, 3. , 3. ]),
 array([6.4, 6.7, 6.3, 6.9, 6.5, 6.5]),
 array([2.2, 2.4, 1.5, 2.3, 2. , 1.8]))
```

Определение парных коэффицентов корреляции

из Малюгин В.И._МСАДЭ_МУ

In [6]:
```
display(Image(filename='image1.png', width=1000))
```

Пусть имеется случайная выборка $\{X_{il}\}(i=1,...,N, l=1,...,n)$ значений анализируемых признаков $X_1,...,X_N \in \Re^1$ объема n. По имеющейся выборке вычисляется оценка ковариационной матрицы:

$$\hat{\Sigma} = \left(\hat{\sigma}_{ij}\right)(\hat{\sigma}_{ii} \equiv \hat{\sigma}_{ii}^2)\ (i,j=1,...,N), \tag{7.6}$$

$$\hat{\sigma}_{ij} = \frac{1}{n-1} a_{ij}, a_{ij} = \sum_{l=1}^{n} (X_{il} - \overline{x}_i)(X_{jl} - \overline{x}_j)\ (\sigma_i^2 \equiv \sigma_{ii},\ a_i^2 \equiv a_{ii}), \tag{7.7}$$

$$\overline{x}_i = \frac{1}{n} \sum_{l=1}^{n} X_{il}\ (i,j=1,...,N). \tag{7.8}$$

Элементы *выборочной ковариационной матрицы* $\hat{\Sigma}$ могут использоваться для расчета соответствующих *выборочных коэффициентов корреляции*. Например, *выборочный парный коэффициент корреляции* определяется по формуле

$$\hat{\rho}_{ij} = \frac{a_{ij}}{a_i a_j} \in [-1,1]\ (i \neq j, i,j=1,...,N); \tag{7.9}$$

По формуле 7.7

In [7]:
```
mean_val_1 = x1.mean().item()
mean_val_2 = x2.mean().item()
mean_val_3 = x3.mean().item()

mean_val_1, mean_val_2, mean_val_3
```

Out[7]:
```
(2.974, 6.588000000000001, 2.0260000000000002)
```

In [8]:
```
a_11 = np.sum((x1 - mean_val_1)**2)
a_22 = np.sum((x2 - mean_val_2)**2)
a_33 = np.sum((x3 - mean_val_3)**2)

a_11, a_22, a_33
```

Out[8]:
```
(np.float64(5.096199999999999),
 np.float64(19.812800000000003),
 np.float64(3.696199999999999))
```

In [9]:
```
a_1 = np.sqrt(a_11)
a_2 = np.sqrt(a_22)
```

```
a_3 = np.sqrt(a_33)

a_1, a_2, a_3
```

Out[9]:
```
(np.float64(2.257476467208462),
 np.float64(4.4511571529210245),
 np.float64(1.9225503894566713))
```

In [10]:
```
a_12 = np.sum((x1 - mean_val_1)*(x2 - mean_val_2))
a_23 = np.sum((x2 - mean_val_2)*(x3 - mean_val_3))
a_13 = np.sum((x3 - mean_val_3)*(x1 - mean_val_1))

a_12, a_23, a_13
```

Out[10]:
```
(np.float64(4.594399999999999),
 np.float64(2.405600000000001),
 np.float64(2.3338))
```

По формуле 7.9

In [11]:
```
r_12 = a_12 / (a_1 * a_2)
r_23 = a_23 / (a_2 * a_3)
r_13 = a_13 / (a_1 * a_3)

r_12, r_23, r_13
```

Out[11]:
```
(np.float64(0.457227816394113),
 np.float64(0.2811077091573194),
 np.float64(0.5377280262661889))
```

Определение частных коэффицентов корреляции

из Малюгин В.И._МСАДЭ_МУ

In [12]:
```
display(Image(filename='image2.png', width=1000))
display(Image(filename='image3.png', width=1000))
```

Определение. *Частным (условным) коэффициентом корреляции* (ЧКК) непрерывных случайных величин X,Y при условии, что значение Z фиксировано, называется характеристика

$$\rho_{X,Y|Z} = \frac{\rho_{X,Y} - \rho_{X,Z}\rho_{Y,Z}}{\sqrt{(1-\rho_{X,Z}^2)(1-\rho_{Y,Z}^2)}} \in [-1,1], \qquad (7.3)$$

где $\rho_{X,Y}$, $\rho_{X,Z}$, $\rho_{Y,Z}$ – парные коэффициенты корреляции Пирсона для соответствующих случайных величин.

С помощью ЧКК $\rho_{X,Y|Z}$ устанавливается причина корреляции двух признаков из двух возможных вариантов 1) между признаками X,Y имеет место прямая зависимость; 2) прямой зависимости нет, причиной корреляции признаков X,Y является действие «третьего фактора» Z на каждый из признаков в отдельности. В первом случае имеем: $\rho_{ij} \neq 0$ и $r_{ij|k} \neq 0$. Во втором случае $\rho_{ij} \neq 0$, а $\rho_{ij|k} = 0$.

По формуле 7.3

In [13]:
```
r_12_3 = (r_12 - r_13 * r_23)/np.sqrt((1 - r_13**2) * (1 - r_23**2))
r_23_1 = (r_23 - r_12 * r_13)/np.sqrt((1 - r_12**2) * (1 - r_13**2))
r_13_2 = (r_13 - r_12 * r_23)/np.sqrt((1 - r_12**2) * (1 - r_23**2))

r_12_3, r_23_1, r_13_2
```

Out[13]:
```
(np.float64(0.37827278871255676),
 np.float64(0.04700217344052275),
 np.float64(0.4794419123083884))
```

Разность частных и парных

In [14]:
```
r_12 - r_12_3, r_23 - r_23_1, r_13 - r_13_2
```

Out[14]:
```
(np.float64(0.07895502768155621),
 np.float64(0.23410553571679665),
 np.float64(0.05828611395780048))
```

Разница между r_12 и r_12_3, а также r_13 и r_13_2 небольшая и значения все еще сильно отличны от нуля
Разница между r_23 и r_23_1 велика и близка к значению r_23, а r_23_1 близка к 0, тогда можно сделать выводы

r_12_3 != 0, между 1 и 2 имеет место прямая зависимость

r_23_1 близок 0, прямой зависимости между 2 и 3 нет, причиной кореляции является действие 1 на каждый из них в отдельности

r_13_2 != 0, между 1 и 3 имеет место прямая зависимость

Проверка статистической значимости корреляционной зависимости

Критерий значимости парного КК

In [15]:
```
display(Image(filename='image4.png', width=500))
display(Image(filename='image5.png', width=800))
```

H_0 не отклоняется, если $P > \varepsilon$

H_0 отклоняется, если $P \leq \varepsilon$,

где P – так называемое P-значение:

$$P = 1 - \int_{-|r_{ij}|}^{+|r_{ij}|} p_0(u)du,$$

$$p_0(u) = \frac{\Gamma(\frac{n-1}{2})}{\sqrt{\pi} \cdot \Gamma(\frac{n-2}{2})}(1-u^2)^{\frac{n-4}{2}}, \quad u \in [-1, +1]$$

Практически это то же самое, что t-критерий Стьюдента с n–2 степенями свободы:

In [16]:
```
display(Image(filename='image6.png', width=400))
```

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

Вычисление t-критерия для n-2

In [17]:
```
n = len(data[data['type'] == 3])
a = 0.05
```

In [18]:
```
t_12 = (r_12 * np.sqrt(n - 2))/(np.sqrt(1 - r_12**2))
t_23 = (r_23 * np.sqrt(n - 2))/(np.sqrt(1 - r_23**2))
t_13 = (r_13 * np.sqrt(n - 2))/(np.sqrt(1 - r_13**2))

t_12, t_23, t_13
```

Out[18]:
```
(np.float64(3.5618919811627627),
 np.float64(2.02940459390154),
 np.float64(4.418702311848506))
```

Вычисление критического значения t для n-2

In [19]:
```
t_crit_pair = sts.t.ppf(1 - a/2, n - 2)

t_crit_pair
```

Out[19]:
```
np.float64(2.010634757624232)
```

Значимость через t

In [20]:
```
print(f"r_12: значим: {abs(t_12) > t_crit_pair}")
print(f"r_23: значим: {abs(t_23) > t_crit_pair}")
print(f"r_13: значим: {abs(t_13) > t_crit_pair}")
```

```
r_12: значим: True
r_23: значим: True
r_13: значим: True
```

Все три парных коэффициента корреляции статистически значимы, но 23 находится на грани(тк значение очень близко к t-критическому)

Вычисление p-значение

In [21]:
```
p_12 = 2 * (1 - sts.t.cdf(abs(t_12), n - 2))
p_23 = 2 * (1 - sts.t.cdf(abs(t_23), n - 2))
p_13 = 2 * (1 - sts.t.cdf(abs(t_13), n - 2))

p_12, p_23, p_13
```

Out[21]:
```
(np.float64(0.0008434624723707707),
 np.float64(0.047981493369188444),
 np.float64(5.647610402292891e-05))
```

Значимость через p

In [22]:
```
print(f"r_12: значим: {p_12 < a}")
print(f"r_23: значим: {p_23 < a}")
print(f"r_13: значим: {p_13 < a}")
```

```
r_12: значим: True
r_23: значим: True
r_13: значим: True
```

Все три парных коэффициента корреляции статистически значимы, но 23 находится на грани(тк значение очень близко к a)

Критерий значимости частного КК

In [23]:
```
display(Image(filename='image7.png', width=500))
```

$$t = \frac{r_{ij|k}\sqrt{n-3}}{\sqrt{1-r_{ij|k}^2}}$$

Вычисление t-критерия для n-3

In [24]:
```
t_12_3 = (r_12_3 * np.sqrt(n - 3))/(np.sqrt(1 - r_12_3**2))
t_23_1 = (r_23_1 * np.sqrt(n - 3))/(np.sqrt(1 - r_23_1**2))
t_13_2 = (r_13_2 * np.sqrt(n - 3))/(np.sqrt(1 - r_13_2**2))

t_12_3, t_23_1, t_13_2
```

Out[24]:
```
(np.float64(2.8014733880303386),
 np.float64(0.32258719410526293),
 np.float64(3.745427265822388))
```

Вычисление критического значения t для n-3

In [25]:
```
t_crit_part = sts.t.ppf(1 - a/2, n - 3)

t_crit_part
```

Out[25]:
```
np.float64(2.0117405137297655)
```

Значимость через t

In [26]:
```
print(f"r_12_3: значим: {abs(t_12_3) > t_crit_part}")
print(f"r_23_1: значим: {abs(t_23_1) > t_crit_part}")
print(f"r_13_2: значим: {abs(t_13_2) > t_crit_part}")
```

```
r_12_3: значим: True
r_23_1: значим: False
r_13_2: значим: True
```

Коэффициенты корреляции 12 и 13 значимы, а 23 нет, тк не t не превосходит t критическое

Вычисление p-значение

In [27]:
```
p_12_3 = 2 * (1 - sts.t.cdf(abs(t_12_3), n - 3))
p_23_1 = 2 * (1 - sts.t.cdf(abs(t_23_1), n - 3))
p_13_2 = 2 * (1 - sts.t.cdf(abs(t_13_2), n - 3))
```

```
p_12_3, p_23_1, p_13_2
```

Out[27]:
```
(np.float64(0.007363589661746328),
 np.float64(0.7484385758269321),
 np.float64(0.0004911883641607329))
```

Значимость через p

In [28]:
```
print(f"r_12_3: значим: {p_12_3 < a}")
print(f"r_23_1: значим: {p_23_1 < a}")
print(f"r_13_2: значим: {p_13_2 < a}")
```

```
r_12_3: значим: True
r_23_1: значим: False
r_13_2: значим: True
```

Коэффициенты корреляции 12 и 13 значимы, а 23 нет, тк p превосходит a

Множественный коэффицент корреляции

In [29]:
```
display(Image(filename='image8.png', width=1000))
display(Image(filename='image9.png', width=1000))
```

Определение. *Множественным коэффициентом корреляции* (ЧКК) между случайной величиной Y и случайными величинами X, Z называется характеристика

$$R \equiv R_{Y,X,Z} = \sqrt{\frac{c_Y' \Sigma_{XZ}^{-1} c_Y}{\sigma_Y^2}} \in [0,1]. \qquad (7.4)$$

На практике чаще используется характеристика «*квадрат множественного коэффициента корреляции*» , для вычисления которого применяется формула

$$R^2 = 1 - \frac{|\Sigma|}{\sigma_Y^2 |\Sigma_{XZ}|} \in [0,1], \qquad (7.5)$$

где $|\Sigma_{XZ}| \neq 0, \ |\Sigma| \leq \sigma_Y^2 |\Sigma_{XZ}|$.

Важной характеристикой адекватности модели является *коэффициент детерминации*, определяемы по формуле:

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (\hat{y}_i - y_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2} = 1 - \frac{RSS}{TSS} \in (0,1). \qquad (7.20)$$

In [30]:
```
R_1_23 = np.sqrt((r_12**2 + r_13**2 - 2 * r_12 * r_13 * r_23)/(1 - r_23**

R_1_23
```

Out[30]:
```
np.float64(0.6251935438247318)
```

In [31]:
```
X_reg = np.column_stack([np.ones_like(x2), x2, x3])
y_reg = x1
beta, *_ = np.linalg.lstsq(X_reg, y_reg, rcond=None)
```

```
y_hat = X_reg @ beta
RSS = np.sum((y_reg - y_hat)**2)
TSS = np.sum((y_reg - y_reg.mean())**2)
R2 = 1 - RSS/TSS
R = np.sqrt(R2)

R_1_23, R2, R
```

Out[31]:
```
(np.float64(0.6251935438247318),
 np.float64(0.39086696724012737),
 np.float64(0.6251935438247322))
```

Значение ВМКК R_1_23 = 0.625... почти в точности совпадает с корнем из ккорнем из коэффициента детерминациии x1 на (x2, x3): sqrt(R2) = 0.625...

F-статистика для проверки значимости ВМКК

In [32]:
```
display(Image(filename='image10.png', width=600))
```

$$F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)}$$

In [33]:
```
k = 3
```

In [34]:
```
F_1_23 = (R_1_23**2/(k-1))/((1 - R_1_23**2)/(n - k))

F_1_23
```

Out[34]:
```
np.float64(15.079421466482763)
```

In [35]:
```
F_crit = sts.f.ppf(1-a, k-1, n-k)

F_crit
```

Out[35]:
```
np.float64(3.1950562807372145)
```

In [36]:
```
print(f"F_1_23: значим: {F_1_23 > F_crit}")
```

```
F_1_23: значим: True
```

In [37]:
```
p_F = 1 - sts.f.cdf(F_1_23, k-1, n-k)

p_F
```

Out[37]:
```
np.float64(8.72439984900275e-06)
```

F_1_23 превышает критическое значение F, p_F < 0.001. Следовательно, на уровне a = 0.05 гипотеза H0: R_1_23 = 0 отвергается — множественный коэффициент

корреляции статистически значим, между x1 и набором (x2, x3) существует значимая линейная зависимость.

Вывод

Все три парных КК значимы (a = 0.05). После исключения влияния третьего фактора r_12_3 и r_13_2 остались значимыми — между X1-X2 и X1-X3 имеет место непосредственная связь. Частный r_23_1 незначим, значит корреляция X2-X3 обусловлена влиянием X1.

ВМКК R_1_23, R2, F (p < 0.001) - значим. Совпадает с sqrt(R2) модели МЛР x1 ~ x2 + x3. Связь x1 с набором (x2, x3) статистически значимая.